#### I. EINLEITUNG

#### Motivation

50% weniger Aufwand bei Anwendungsentwicklung mit DB Ermöglicht neue Anwendungen, die ohne DB zu komplex wären Ausfaktorisieren der Verwaltung großer Datenmengen ohne Datenbanken

Daten in Dateien abgelegt, Zugriffsfunktionalität Teil der Anwendung

Redundanz (in Daten und Funktionalität)

Programme oft nicht atomar (= Programm wird entweder ganz oder gar nicht ausgeführt) – nur bei nicht fehlerfreien Systemen relevant.

Transaktionen (= Programm oder Kommandofolge) oft nicht isoliert (= keine inkonsistenten Zwischenzustände sichtbar) – nur bei mehreren Transaktionen, aber auch bei fehlerfreien Systemen relevant

Nebenläufigkeit (concurrency – paralleler Zugriff auf dieselben Daten) schwer umsetzbar

Anwendungsentwicklung abhängig von der physischen Repräsentation der Daten (z.B. Datenspeicherung als Tabelle: Reihenfolge Zeilen/Spalten muss bekannt sein)

 $\label{eq:definition} \begin{aligned} & \text{Datenschutz} \; (= \text{kein unbefugter Zugriff}) \; \text{nicht gewährleistet} \\ & \text{Datensicherheit} \; (= \text{kein Datenverlust, insb. bei Defekten}) \\ & \text{nicht gewährleistet} \end{aligned}$ 

#### Relationale Datenbanken

auch <u>RDBMS</u> (relational database management system)

≅ Menge von Tabellen

 ${\bf Relation = Menge\ von\ Tupeln = Tabelle}$ 

### RDBMS - Terminologie

 $\frac{\text{Relationenschema}\text{: }\mathbf{Fett}\text{ geschrieben}}{\text{Relation}\text{: Weitere Einträge der Tabelle}}$ 

Tupel: Eine Zeile der Tabelle
Attribut: Spaltenüberschrift
Relationenname: Name der Tabelle

 $\underline{DBS} \hbox{: } Datenbanksystem = DBMS \, + \, Datenbank(en)$ 

 $\underline{\operatorname{Schl\"{u}ssel}} :$  Attribut, das nicht doppelt vergeben werden darf

 $\underline{\underline{\text{Fremdschlüssel}}};$  Attribut taucht in anderem Relationenschema als Schlüssel auf

Integritätsbedingungen:

- 1. lokal: Schlüssel in Relationenschema
- 2. global: Fremdschlüssel in Datenbankschema

 $\underline{\mbox{DB-Schema}}:=\mbox{Menge}$ der Relationsschemat<br/>a+globale Integritätsbedingungen

 $\underline{\rm Sicht}$   $(view)\colon$  Häufig vorkommende Datenabfrage, kann mit Sichtnamen als "virtuelle" Tabelle gespeichert werden

create view CArtist as
 select NAME, JAHR
 from Kuenstler
 where LAND == "Kanada"

Verwendung wie "normale" Relation:

 $\mathbf{select} \ * \ \mathbf{from} \ \mathsf{CArtist} \ \mathbf{where} \ \mathsf{JAHR} \ < \ 2000$ 

Nutzung für Datenschutz: Unterschiedliche Benutzer sehen unterschiedlichen DB-Ausschnitt

# ${\bf RDBMS-An frage operation en}$

<u>Selektion</u>: Zeilen (Tupel) wählen  $(\sigma_{KID=1012}(Titel))$ 

Projektion: Spalten (Attribute) wählen ( $\pi_{\text{KID, NAME}}(\text{Kuenstler}))$ 

Beispiel komplexer Ausdruck:  $\pi_{\text{NAME,ART}}(\sigma_{\text{KID}=1012}(\text{Titel}))$ 

## Ausgangsrelation:

ſ	TITLE ID	NAME	ART	GRÖSSE	KID
ĺ	102	Neil Young - Heart of Gold	mp3	2.920kb	1012
١	103	Rammstein –	wma	4.234kb	1014
١		Ich liebe Neil Young			
١		Neil Young – Old Man	mp3	3.161kb	1012
١	105	Neil Young –	wma	5.125kb	1012
١		Four Strong Winds			

Ergebnis:

NAME	ART
Neil Young - Heart of Gold	mp3
Neil Young – Old Man	mp3
Neil Young –	wma
Four Strong Winds	

Weitere Operationen: Verbund (join), Vereinigung, Differenz, Durchschnitt, Umbenennung

Operationen beliebig kombinierbar (→ Query-Algebra)

# ${\bf RDBMS-An frage noptimier ung}$

Algebraische Ausdrücke äquivalent, Anfrage aber unterschiedlich komplex, z.B.

 $\sigma_{\text{Vorname}=\text{'Klemens'}}(\sigma_{\text{Wohnort}=\text{'KA'}}(SNUSER)) \text{ vs.}$ 

 $\sigma_{\text{Wohnort}=\text{'KA'}}(\sigma_{\text{Vorname}=\text{'Klemens'}}(SNUSER))$ 

#### RDBMS - Physische Datenunabhängigkeit

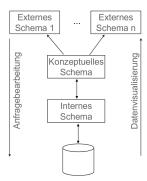
Anfragen  $\underline{\text{deklarativ}}$ : Nutzer entscheidet nicht, wie Ergebnis ermittelt wird

Datenunabhängigkeit: DBMS stellt sicher:

- $1.\,$ stabile Anfragenfunktionalität bei physischer Darstellungsänderung
- 2. Anfrage funktinoiert bei unterschiedlichen Datenbanken (gleiches Schema, unterschiedliche Datenhäufigkeit)

→ erlaubt höhere Komplexität bei Anwendungsentwicklung

### RDBMS - 3-Ebenen-Architektur



Konzeptionelles Schema: Diskursbereich? Welche Entitäten interessant (bei Studierenden Noten interessant, Hobbies usw. nicht)?

<u>Internes Schema</u>: physische Datenrepräsentation

Externe Schemata: Unterschiedlicher Datenausschnitt für unterschiedliche Nutzer (Datenschutz, Übersichtlichkeit, organisatorische Gründe, Verstecken von Änderungen am konzeptionellen Schema)

 $\leadsto$  Logische Datenunabhängigkeit

# Datenbankprinzipien – Coddsche Regeln

- 1. Integration: Einheitliche, nichtredundante Datenverwaltung
- 2. Operationen: Speichern, Suchen, Ändern
- 3. Katalog: Zugriff auf Datenbankbeschreibungen im data directory
- 4. Benutzersichten
- 5. Integritätssicherung: Korrektheit des DB-Inhalts
- 6. <u>Datenschutz</u>: Ausschluss unauthorisierter Zugriffe
- 7.  $\frac{\text{Transaktionen:}}{\text{Atomarität}}$  mehrere DB-Operationen als Funktionseinheit (=
- 8. <u>Synchronisation</u>: parallele Transaktionen koordinieren (= Isolation)
- 9. Datensicherung: Wiederherstellung von Daten nach Systemfehlern

Strengste bekannte Datenbankdefinition

Funktionale Anforderungen (nichtfunktional z.B.: Wie schnell/zuverlässig muss Dienst sein, kurze Antwortzeiten, Zuverlässigkeit, Effizienz, Skalierbarkeit)

#### Prüfungsfragen

- 1. Was ist eine Sicht?
- 2. Was ist die relationale Algebra? Wozu braucht man sie?
- 3. Geben Sie Beispiele für Algebra-Ausdrücke an, die nicht identisch, aber äquivalent sind, an.
- 4. Was leistet der Anfragenoptimierer einer Datenbank?
- 5. Erklären Sie: Drei-Ebenen-Architektur, physische/logische Datenunabhängigkeit.

## II. CLUSTERING UND AUSREISSER

### Räumliche Indexstrukturen - Motivation

Was ist die nächste Bar, die mein bevorzugtes Bier ausschenkt? Bereichsanfrage: Wie viele Restaurants gibt es im Stadtzentrum?

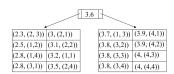
Ähnlichkeitssuche Bilder: Distanz im Merkmalsraum = Maß der Unähnlichkeit

Ziel eines  $\underline{\operatorname{Index}} \colon \operatorname{Zahl}$ der zu ladenden Seiten minimieren

# $\mathbf{Index} - \mathbf{B} \mathbf{+-tree}$

 $= {\rm non\text{-}clustered\ primary\ B+\text{-}tree}$ 

Beispiel: Student(name, age, gpa, major), B+T für gpa (kleiner=links, größer=rechts, (gpa, (Seite, Eintrag)))



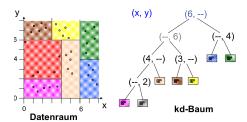
Tom, 20, 3.2, EE	Mary, 24, 3, ECE	Lam, 22, 2.8, ME	Chris, 22, 3.9, CS
Chang, 18, 2.5, CS	James, 24, 3.1, ME	Kathy, 18, 3.8, LS	
Bob, 21, 3.7, CS	Chad, 28, 2.3, LS	Kane, 19, 3.8, ME	Louis, 32, 4, LS
Pat, 19, 2.8, EE	Leila, 20, 3.5, LS	Martha, 29, 3.8, CS	Shideh, 16, 4, CS

#### Index - kd-tree

 $\mathrm{B}{+}\mathrm{T}$ löst Bar-Problem nicht wirklich

kd-tree: Splitting für eine Dimension nach der anderen, dann wieder von vorne

Beispiel: Vier Split-Dimensionen



#### kd-tree – k-NN

k-NN (= k-next-neighbour) := Abstand des k-nächsten Nachbarn Es müssen nur ein paar kd-Baum-Regionen inspiziert werden, um Resultat zu ermitteln (Abstand zu Region ist untere Schranke)

Implementierung: Priority Queue (Datenobjekte/Baumknoten, sortiert nach Abstand zum Anfragepunkt) initialisiert mit Wurzelknoten; Vorderstes Objekt aufspalten und Teilobjekte einfügen; Ende wenn Punkt vorne in Queue

Hier: Baum unbalanciert, Balancierung in Realität für mehrdimensionale Daten

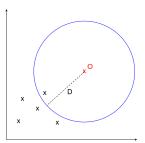
#### Outlier

Element des Datenbestands, das in bestimmter Hinsicht erheblich vom restlichen Datenbestand abweicht

Mögliche Definition:

Objekt O, das in Datenbestand T enthalten ist ist ein  $\mathrm{DB}(p,D)$ -Outlier, wenn der Abstand von O zu mindestens p Prozent der Objekte in T größer ist als D.

Beispiel: O ist Outlier, wenn p=0.6, da dann mehr als 60% der Datenobjekte außerhalb des Kreises liegen



# Outlier - Index-basiert

Punkt ist kein Outlier, wenn k-Abstand < D mit k = N\*(1-p)-1 Für ieden Punkt:

k-NN Query, dabei stoppen sobald größte noch mögliche k-NN Distanz < D (Baumknoten mit k Objekten und größter Distanz < D)

 $\label{eq:Viele} \mbox{Viele weitere Ans\"{a}tze, z.B.}$ 

Clustering: Liefert Outlier als Beiprodukt

## Clustering – Beispiel Customer Segmentation

Große Kundendatenbank mit Eigenschaften und Käufen Gesucht: Gruppen von Kunden mit ähnlichem Verhalten finden

#### Clustering - DBSCAN

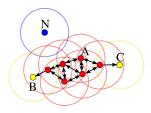
Dichte: Anzahl Objekte pro Volumeneinheit

 $\frac{\text{Dichtes Objekt: mindestens } x \text{ andere Objekte in Kugel um Objekt}}{\text{mit Radius } \epsilon} \text{ (A)}$ 

 $\frac{\text{Dichte-erreichbares Objekt: Objekt in }\epsilon\text{-Umgebung eines dichten}}{\text{Objekts, das selbst nicht dicht ist (B, C)}}$ 

Clusterrand, Zuordnung zu Clustern ist nichtdeterministisch

<u>Rauschen</u> (*Noise*): Objekte, die von keinem dichten Objekt erreicht werden können (N)



### DBSCAN - Eigenschaften

 $\leadsto$ mehrdimensionale Index<br/>struktur sehr sinnvoll

Rauschen liefert mögliche Outlier (DBSCAN erstellt Vorauswahl)

# Hochdimensionale Datenräume – Anomalien

Curse of dimensionality

 $\underline{\operatorname{Sparsity}} \colon \operatorname{Raum}$ ist nur dünn mit Punkten besetzt

Hierarchische Datenstrukturen ineffektiv: Es müssen immer alle Blätter betrachtet werden

Keine echten Outlier: bei sehr, sehr vielen Dimensionen ist Abstand zweier Datenobjekte fast gleich dem zweier anderer  $\leadsto$  Outlier-Algorithmen liefern mehr oder weniger zufälliges Objekt

 $\leadsto$ nur erfolgsversprechende Teilräume nach Ausreißern absuchen Interessante Cluster sind i.d.R. nicht Cluster in allen Dimensionen

## Outlier - im Höherdimensionalen

Outlier erscheinen als solche nur in Teilräumen

Manche Teilräume ausreißerfrei

Unterschiedlichdimensionale Teilräume enthalten Ausreißer trivial vs. nichttrivial:

- 1. trivial: Objekt ist in Teilraum bereits Ausreißer
- 2. **nichttrivial**: Gegenteil
- $\leadsto$  Maß für Teilraumrelevanz wie findet man relevante TR?

## Subspace Search

Exponentiell viele Teilräume P(A)

Auswahl relevanter Teilräume  $RS \subset P(A)$ 

# HiCS-Prinzip

Attribute korrelieren nicht → Outlier in diesem Raum tendenziell eber trivial

<u>Idee</u>: Suche nach Verletzung statistischer Unabhängigkeit (= **Kontrast**)

#### Prüfungsfrager

- 1. Warum kann man räumliche Anfragen nicht ohne Weiteres auswerten, wenn man für jede Dimension separat einen B-Baum angelegt hat?
- 2. Wie funktioniert der Algorithmus für die Suche nach den k nächsten Nachbarn mit Bäumen wie dem kd-Baum?
- 3. Warum werden bei der NN-Suche nur genau die Knoten inspiziert, deren Zonen die NN-Kugel überlappen?
- 4. Was ist ein Outlier?
- 5. Was ist ein Zusammenhang zwischen k-NN-Suche mit Bäumen wie dem kd-Baum und Outlier-Berechnung?
- 6. Warum ist die Zuordnung Dichte-erreichbarer Punkte mit DBSCAN nichtdeterministisch?
- 7. Warum sind hierarchische Datenstrukturen in hochdimensionalen Merkmalsräumen für die k-NN-Suche nicht das Mittel der Wahl?
- 8. Was bedeutet Subspace Search?
- 9. Geben Sie die Unterscheidung zwischen trivialen und nichttrivialen Outliern aus der Vorlesung wieder.
- 10. Was genau bedeutet Kontrast im Kontext von HiCS?

## III. DATENBANK-DEFINITIONSSPRACHEN

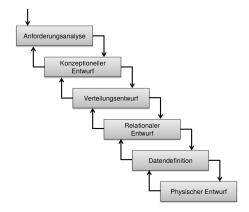
## Gewinnung der Konventionen

Beschränkte Anwendungswelt (= Miniwelt, relevanter Weltausschnitt, Diskursbereich)

Daten: Modelle (gedankliche Abstraktionen) der Miniwelt

<u>Datenbasiskonsistenz</u>: Datenbasis ist bedeutungstreu, wenn ihre <u>Elemente Modelle einer gegebenen Miniwelt sind</u> (schärfste Konsistenzforderung)

### Datenbankentwurf-Phasen modell



### Datenbankentwurf - Modellierung

Ausschnitt der Wirklichkeit mit Schema beschreiben

Typen = Struktur der Entitäten

Welche Konsistenzbedingungen sind sinnvoll?

 $\frac{\text{Schemakonsistenz}}{\text{Konsistenzbedingungen}} \leftarrow \text{Einhaltung der durch Schema vorgegebenen} \\ \text{Konsistenzbedingungen} (= \text{von DBMS "überprüfbar!})$ 

# $\mathbf{SQL}$

=standardisierte Sprache für DB-Zugriff (relational) Aspekte:

- 1. Schemadefinition
- 2. Datenmanipulation (Einfügen, Löschen, Ändern)
- 3. Anfragen

#### SQL - SQL-DDL

 $= SQL \ data \ definition \ language$ 

Teilbereich von SQL, der zu tun hat mit Definition von:

- 1. Typen
- 2. Wertebereichen
- 3. Relationsschemata
- 4. Integritätsbedingungen

## SQL - als Definitionssprache

1. Externe Ebene:

```
{ create | drop } view;
```

2. Konzeptuelle Ebene:

```
{ create | alter | drop } table;
{ create | alter | drop } domain;
```

3. Interne Ebene:

```
{ create | alter | drop } index;
```

#### **Data Dictionary**

Verzeichnis der vorhandenen Tabellen und Sichten

Selbst wie eine Datenbank aufgebaut

Enthält keine Anwendungsdaten, sondern Struktur-Metadaten

#### ${\bf SQL-Tabelle~anlegen}$

```
create table Kuenstler
  (KID integer, NAME varchar(200),
  LAND varchar(50) not null, JAHR integer,
  primary key (KID))
```

#### SQL - Wertebereiche

```
integer (auch int)
smallint
float(p) (auch float)
decimal(p,q) (auch numeric(p,q), jeweils mit q Nachkommastel-
len)
character(n) (auch char(n) oder char für n = 1)
character varying(n) (auch varchar(n), String variabler Länge
bis Maximallänge n)
bit(n) (oder varying(n) analog für Bitfolgen)
date, time, timestamp
```

## Wertebereiche – Custom

```
create domain Gebiete varchar(20)
  default 'Informatik'

create table Vorlesungen
  (Bezeichnung varchar(80) not null, SWS smallint,
    Semester smallint, Studiengang Gebiete)
```

# Integritätsbedingungen

Schlüssel kann aus mehreren Attributen bestehen

Studiengang Gebiete)

## <u>Fremdschlüssel</u>:

```
create table Titel
  (TITLEID integer not null, NAME varchar(200),
   KID integer, primary key (TITLEID),
  foreign key (KID) references Kuenstler(KID))

default-Klausel: Standardwert für Attribut
check-Klausel: weitere lokale Integritätsbedingungen
  create table Vorlesungen
  (Bezeichnung varchar(80) not null, SWS smallint,
   Semester smallint, check(Semester between 1 and 9),
```

## $\mathbf{SQL}$ – alter und drop

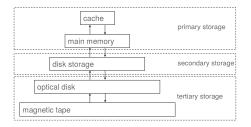
```
alter table Lehrstuehle
  add Budget decimal(8,2)
  add constraint Namekey primary key (Name, Vorname)
```

→ Änderung Relationsschema im Data Dictionary, existierende Daten werden um null-Attribut erweitert

```
drop spaltenname { restrict | cascade }
drop table basisrelationenname { restrict | cascade }
```

- $\leadsto$  Attribut / Tabelle löschen, dabei gilt:
  - 1.  ${\tt restrict}$ : keine Sichten/Integritätsbedingungen mit diesem Attribut definiert wurden
  - cascade: gleichzeitig diese Schichten/Integritätsbedingungen mitgelöscht werden sollen

#### Speicherhierarchie



#### Index

Für mehrere Attribute möglich

Index für (gpa, name)  $\neq$  Index für (name, gpa)

Index kann nachträglich angelegt bzw. gelöscht werden, ohne Daten selbst zu löschen

Index Bestandteil der physischen Ebene, Index-Definition Teil des internen Schemas

select name from Student where gpa > 4 liefert Ergebnis unabhängig von Existenz eines Index – wenn vorhanden erhebliche Beschleunigung

create [unique] index typ on auto(hersteller, modell, baujahr)
hilft bei Herstellersuche, weniger bei Suche nach Baujahr

Unique Index zur Simulation von Schlüsselbedingungen



### Prüfungsfragen

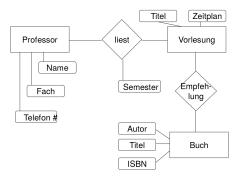
- Erläutern Sie anhand eines Anwendungsbeispiels, warum man die Menge der zulässigen Zustände einschränken will
- $2.\ \, {\rm Was\ ist\ Schema-Konsistenz},\, {\rm Datenbasis-Konsistenz}?$
- 3. Was ist ein (DB-)Schema?
- 4. Was ist das Data Dictionary?
- 5. Warum sollte man sich die Mühe machen, Integritätsbedingungen als Teil des DB-Schemas zu formulieren?
- Sind Integritätsbedingungen Bestandteil des internen oder des konzeptuellen Schemas? Begründen Sie Ihre Antwort.
- 7. Wieso sind Indices Bestandteil des internen und nicht des konzeptuellen Schemas?
- 8. Geben Sie Beispiele für DB-Features an, die zeigen, dass DB-Systeme physische Datenunabhängigkeit nicht vollständig umsetzen.

# IV. DATENBANKMODELLE FÜR DEN ENTWURF

# Entity-Relationship-Modelle

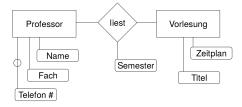
 $\underline{\underline{Entity}} . \label{eq:constraint} \underline{\underline{Constraint}} \underline{\underline{Constraint}} . \label{eq:constraint} \underline{\underline{Constraint}} \underline{\underline{Constraint}} . \label{eq:constraint} \underline{\underline{Constraint}} \underline{\underline{Co$ 

Attribut: Eigenschaft von Entities (z.B. ISBN)



#### Attribute

 $\frac{\text{Mengenwertig:}}{\text{Optional:}} \text{ Durch Doppelrand gekennzeichnet}$ 



### ER - Modellierungskonzepte

 $\mu(D) \colon \text{Interpretation von } D,$ mögliche Werte einer Entity-Eig.

 $\mu(\texttt{int}) \colon \mathbb{Z}, \, \mu(\texttt{string}) \colon C^\star$  (Folgen von Zeichen aus C)

 $\mu(E) {:}$  Menge der möglichen Entities vom TypE

 $\sigma_i(E)$ : Menge der aktuellen Entities vom TypE in Zustand  $\sigma \leadsto \sigma(E) \subseteq \mu(E)$  und  $\sigma(E)$ endlich

 $\mu(R) = \mu(E_1) \times \cdots \times \mu(E_n)$ 

→ Die Menge aller möglichen Ehen ist die Menge aller (Mann,Frau)-Paare.

 $\sigma(R) \subseteq \sigma(E_1) \times \cdots \times \sigma(E_n)$ 

 $\rightarrow$  aktuelle Beziehungen nur zwischen aktuellen Entities

Attribut Aeines Entity-Typen Eist im Zustand  $\sigma$ eine Abbildung  $\sigma(A):\sigma(E)\to \mu(D)$  (nicht  $A:\sigma(E)\to \mu(D)$ 

Beziehungsattribute:  $\sigma(A):\sigma(R)\to \mu(D)$  (Beziehung R, Attribut A, möglicher Wertebereich  $\mu(D)$ )

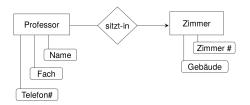
## Mehrstellige Beziehungen

Umwandlung von mehrstelligen Beziehungen in mehrere einstellige Beziehungen i.A. nicht einfach möglich.

### Funktionale Beziehungen

Jedem Professor lässt sich ein Zimmer zuordnen, umgekehrt nicht zwingend

Schreibe:  $R: E_1 \to E_2$ 



#### Schlüssel

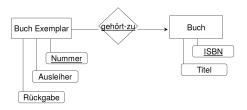
Schlüsselattribute  $\{S_1,\dots,S_k\}\subseteq\{A_1,\dots,A_m\}$  für Entity-Typ $E(A_1,\dots,A_m)$ 

Notation: Schlüssel unterstreichen:  $E(\ldots, \underline{S_1}, \ldots, \underline{S_i}, \ldots)$ 

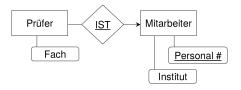
Schlüssel ist minimal: Wird ein Schlüsselattribut entfernt, so ist das entstehende Tupel nicht mehr eindeutig

### Abhängige Entity-Typen

Identifikation über funktionale Beziehung (als Schlüssel) Bsp: (Exemplar-)Nummer bezieht sich auf jeweiliges Buch

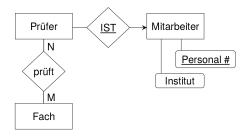


## IST-Beziehung



Spezialfall eines abhängigen Entity-Typen (nur Beziehung als Schlüssel)

Vererbung von Attributen (und Werten):  $\sigma(Pr\ddot{u}fer) \subseteq \sigma(Mitarbeiter)$ 



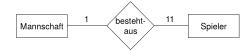
# Entwurf – Kardinalitäten

An wv. Beziehungen muss Entity teilnehmen? → einschränken Teilnehmerkardinalität: arbeitet\_in(Mitarbeiter[0,1],Raum[0,3])

- 1. jeder Mitarbeiter hat einen oder keinen zugeordneten Raum
- 2. pro Zimmer arbeiten maximal drei Mitarbeiter
- 3. ein Zimmer kann leerstehen

 $\frac{\underline{Standardkardinalit"at:}}{\underline{Auch\ hier\ Intervallangabe\ m"oglich}}$ 

Speziell: m:n/1:n/1:1-Beziehung (Untere Schranke jeweils  $\mathbf{0}$ )



#### Semantische Beziehungen

Spezialisierung: Pruefer Spezialisierung von Mitarbeiter

→ Vererbung (IST-Beziehung)

Partitionierung: Spezialfall der Spezialisierung, mehrere disjunkteEntity-Typen (z.B. Partitionierung von Buch in Monographie und Sammelband)

Generalisierung: Buch oder DVD als Medium

Medium ist stets DVD oder Buch

Aber: Buch muss kein Medium sein.

 $Aggregierung: Auto \ besteht \ aus \ Motor, \ Karosserie, \dots$ 

ightarrow Entity aus Instanzen anderer Entity-Typen zusammengesetzt

Sammlung (auch Assoziation): Team ist Gruppe von Person → Mengenbildung

#### EER.

## = Erweitertes ER-Modell

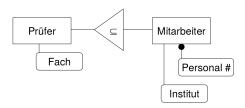
Übernommen: Werte, Entities, Beziehungen, Attribute, Funktionale Beziehungen, Schlüssel (jetzt ausgefüllter Kreis)

Nicht übernommen: IST-Beziehung - ersetzt durch Typkonstruk-

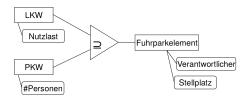
#### EER - Typkonstruktor

Ermöglicht Spezialisierung, Generalisierung, Partitionierung Eingabetypen mit Dreiecksbasis verbunden (bei Generalisierung spezielle Typen, bei Spezialisierung/Partitionierung allgemeine

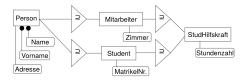
Ausgabetypen mit Spitze verbunden



Spezialisierung



Generalisierung



Mehrfache Spezialisierung

- 1. Wie ist die Semantik von Datenmodellen definiert?
- 2. Geben Sie ein Beispiel für mehrstellige Beziehungen an und erläutern Sie, warum der Sachverhalt mit mehreren zweistelligen Beziehungen nicht korrekt darstellbar wäre.
- 3. Welche semantischen Beziehungen aus dem EER-Kontext kennen Sie? Erläutern Sie die Unterschiede und geben Sie jeweils ein Beispiel an.

### V. RELATIONENENTWURF

## Formalisierung Relationenmodell

Universum U: nichtleere endliche Menge U $\overline{(z.B.\ U = \{Name, Alter, Haarfarbe, ...\})}$ Attribut:  $A \in U$ 

<u>Domäne</u>  $D \in \{D_1, \ldots, D_m\}$ : endliche, nichtleere Menge  $(z.B. D_1 = \{1, 2, 3, ...\}, D_2 = \{schwarz, rot, blond\})$ 

Attributwert:  $w \in \text{dom}(A)$  Attributwert für A, dom :  $U \to D$ :  $\overline{\text{total definierte Funktion, dom}(A)}$  Domäne von A $(z.B. dom(Haarfarbe) = \{schwarz, rot, blond\})$ 

Relationenschema:  $R \subseteq U$ 

Tupel (t in  $R = \{A_1, \ldots, A_n\}$ ):  $t: R \to \bigcup_{i=1}^n D_i$ 

Relation (r über  $R = \{A_1, \ldots, A_n\}$ ): endliche Menge von Tupeln Notation: r(R) (Relation r, Relationenschema R)

> Name Alter Haarfarbe Andreas 43 blond 42 Gunter blond 25 Michael schwarz

Beispiel:

r

 $R = \{Alter, Haarfarbe, Name\}$ 

r besteht aus Tupeln  $t_1, t_2, t_3; t_1(Name) = "Andreas" usw.$ 

 $\underline{REL}: REL(R) = \{r \mid r(R)\}\$ 

Menge aller Relationen über R sind

 $(r \text{ oben: } r \in \text{REL}(\{\text{Name}, \text{Alter}, \text{Haarfarbe}\}),$ 

aber  $r \notin REL(\{Name, Vorname\}))$ 

 $\underline{\text{Datenbankschema}}: S = \{R_1, \dots, R_p\}$ 

Menge von Relationenschemata

 $\underline{\text{Datenbank}}\ (d\ \text{\"{u}ber}\ S) \text{: Menge von Relationen}$ 

 $d = \{r_1, \ldots, r_p\}$  und  $r_i(R_i)$ d(S)Datenbankdüber S

### Lokale Integritätsbedingung

Abbildung aller möglichen Relationen zu einem Schema auf true oder false

 $b: REL(R) \rightarrow \{ true, false \} (b \in B)$ 

Erweitertes Relationenschema:  $\mathcal{R} = (R, B)$ 

Abkürzung:

r(R) – r ist Relation von R

 $r(\mathcal{R})$  – r ist Relation von R, und b(r)= true für alle  $b\in B$ 

 $\underline{SAT}: SAT_R(B) = \{r \mid r(\mathcal{R})\}\$ 

Menge aller Relationen über erweitertem Relationenschema (SAT = satisfy)

### Schlüssel

Schlüssel und Fremdschlüssel einzige Integritätsbedingungen im relationalen Modell

Schlüssel: Minimale identifizierende Attributmenge

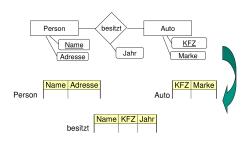
i.A. mehrere Schlüsselkandidaten, ein ausgezeichneter Primärschlüssel

Fremdschlüssel  $X(R_1) \to Y(R_2)$ :

 $\{t(X) \mid t \in r_1\} \subset \{t(Y) \mid t \in r_2\}$  und Y ist Schlüssel von  $R_2$ 

- 1. Wie definieren wir
  - (a) Relation,
  - (b) Relationenschema,
  - (c) Integritätsbedingung?

### VI. ABBILDEN - ER ZU RELATIONAL



#### Abbildungsziel

Kapazitätserhaltende Abbildung: In beiden Fällen gleich viele Instanzen darstellbar

Kapazitätserhöhende Abbildung: relational mehr darstellbar als mit ER

Kapazitätsvermindernde Abbildung: relational weniger darstellbar als mit ER

### Abbildungsregeln

Entity-/Beziehungstypen  $\leadsto$  Relationenschemata Attribute → Attribute Relationenschema Schlüssel --- übernehmen

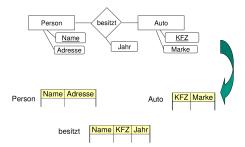
Kardinalitäten  $\leadsto$  Schlüsselwahl

Ggf. Relationenschemata und Entity-/Beziehungstypen verschmelzen

Einführung neuer Fremdschlüsselbedingungen

- 1. Teil der Schema-Definition
- 2. Entstehen bei Abbildung von Relationships
- 3. Ersetzen Linie von Relationship zu Entity

Beziehungstyp  $\rightsquigarrow$  Relationenschema mit Attributen des Beziehungstyps und Primärschlüssel der beteiligten Entity-Typen



- 1. Warum gibt es im ER-Modell keine Fremdschlüssel?
- 2. Was bedeutet "kapazitätserhaltende Abbildung"? Geben Sie Beispiele.
- 3. Wiedergabe der unterschiedlichen Beziehungsabbildungen (1:1, 1:n, m:n)
- 4. In welchen Fällen lässt sich das Schema optimieren? Was bedeutet Optimierung hier?
- 5. Wie lassen sich mengenwertige Attribute abbilden?
- 6. Warum ist Abbildung der folgenden Konstrukte vom ER-Modell ins Relationenmodell problematisch? Rekursive Beziehungen, Partitionierung, Generalis.

### VII. RELATIONALER DATENBANKENTWURF

#### Universalrelation

Universal relation (von  $R_1, \ldots, R_n$ ):  $R = R_1 \bowtie \cdots \bowtie R_n$ Universalschlüssel: Schlüssel der Universalrelation Beispiel:  $R_1, R_2, R_3$ :



 $R_1 \bowtie R_2 \bowtie R_3$ :

PANr	PLZ	Ort	Bundesland

#### Funktionale Relation

 In Relation R(X,Y) ist Y von X funktional abhängig (schreibe  $X\to Y)$ , falls zu jedem  $X ext{-Wert}$  genau ein  $Y ext{-Wert}$  gehört (z.B. Buchtitel, ISBN-Nummer oder Stadt, Bundesland)

 $\rightsquigarrow$  "X bestimmt Y"

F: Menge von FDs (functional dependencies),  $f \in F$  einzelne FD F impliziert f: F| = f

<u>Hülle</u>:  $F_R^+ = \{ f \mid (f \text{ FD "über} R) \land F | = f \}$  $\underline{\text{Transitiv}} \colon \text{PLZ} \to \text{Ort} \to \text{Bundesland}$ 

 $\rightsquigarrow$  PLZ  $\rightarrow$  Bundesland

Projektiv: ISBN  $\rightarrow$  Autor Verlag

 $\longrightarrow$  ISBN  $\rightarrow$  Autor

Äquivalente FD-Mengen (Überdeckungen):  $F \equiv G$  falls  $F^+ = G^+$ 

#### Anomalien

VNr	Bez	PANr	Name	Büro
123	Datenbanksysteme	321	Böhm	367
456	Datenhaltung in der Cloud	321	Böhm	367
789	Workflow-Management	432	Mülle	370

Updateanomalie: Büro von Böhm ändert sich

- → Änderung mehrerer Einträge
- → Aufwendig, fehleranfällig. Wie vermeiden?

Einfügeanomalie: Neuer Dozent ohne VL (NULL-Werte)

→ Was wenn VNr Schlüssel?

Löschanomalie: Mülle hält Workflow nicht mehr

→ Tupel löschen → Müssel-Information verloren

### Abhängigkeitstreue

Beispiel: (InvNr, Titel, ISBN, Autor) oder (InvNr, Titel, <u>ISBN</u>), (<u>ISBN</u>, <u>Autor</u>) oder (InvNr, Titel, <u>ISBN</u>), (<u>ISBN</u>, Autor)?

Abhängigkeitstreu: Alle gegebenen Abhängigkeiten sind durch Schlüssel repräsentiert

# Verbundtreue

Originalrelationen können durch Verbund der Basisrelationen wiedergewonnen werden

#### Entwurfsziel

Relationenschemata, (Fremd-)Sclüssel so wählen, dass

- 1. alle Anwendungsdaten aus Basis<br/>relation hergeleitet werden können (Verbundtruee)
- 2. nur semantisch sinnvolle und konsistente Anwendungsdaten dargestellt werden können ( $Abh\ddot{a}ngigkeitstreue$ )
- 3. möglichst nicht-redundante Daten

#### Erste Normalform

Nur atomare Attribute in Relationenschemata

#### Zweite Normalform

 $\frac{\text{Volle FD: }\beta\text{ ist voll funktional abhängig von }\alpha\text{, wenn aus }\alpha\text{ kein}}{\text{Attribut entfernt werden kann, so dass FD immer noch gilt.}}$ 

Gegenbeispiel: PLZ, Bundesland  $\rightarrow$  Ort

 $\frac{\text{Partielle FD: liegt vor, wenn ein Nicht-Primattribut voll funktional von einem Teil eines Schlüsselkandidaten abhängt}$ 

Zweite NF: keine partiellen Abhängigkeiten

→ Durch Struktur der Abhöngigkeiten Redundanzen entdecken

#### **Dritte Normalform**

 $\frac{\text{Transitive Abhängigkeit: Schlüssel } K \text{ bestimmt Attributmenge } X}{\text{funktional, ist selber aber auch Attributmenge } Y} \\ \rightsquigarrow \text{transitive Abhängigkeit} \rightarrow X \rightarrow Y$ 

<u>dritte NF</u>: Keine transitiven Abhängigkeiten zwischen einem möglichen Schlüssel und weiteren nicht-Primattributen

Erreichen durch Elimination von Y und Kopie von X

3NF impliziert 2NF, da partielle Abhängigkeit Spezialfall von transitiver Abhängigkeit

## Boyce-Codd-Normalform

Relationenschema  $\mathcal{R}$  mit FDs F ist in BCNF, wenn für jede FD  $\alpha \to \beta$  eine der folgenden Bedingungen gilt:

- 1.  $\beta \subseteq \alpha$  (triviale Abhängigkeit)
- 2.  $\alpha$  Schlüssel von  $\mathcal R$  (oder Obermege eines Schlüssels von  $\mathcal R\mathcal L$ )

liefert Zerlegung von  $\mathcal{R}_i$  in  $\mathcal{R}_{i1} = (\alpha \cup \beta)$ ,  $\mathcal{R}_{i2} = \mathcal{R}_i - (\alpha \cup \beta)$   $(F \ni f : \alpha \to \beta, \beta \text{ maximal})$ 

## Minimalität

Ziel: Kiterien mit möglichst wenigen Relationenschemata erreichen

### Dekomposition

Prinzip: Immer wenn  $X \to Y \to Z$  wird Relation zerlegt

erreicht nur 3NF und Verbundtreue

Normalisierung: Falls  $K \to X \to Y$ , dann Y aus R entfernen und mit X in neues Relationenschema stecken

 $\begin{array}{l} \text{Beispiel: } U = \{\text{PANr, PLZ, Ort, Land, Staat}\}, \\ F = \{\text{PANr} \rightarrow \text{PLZ, PLZ} \rightarrow \text{Ort, Ort} \rightarrow \text{Land, Land} \rightarrow \text{Staat}\} \\ \sim (U, K(F)) = (\{\text{PANr, PLZ, Ort, Land, Staat}\}, \{\{\text{PANr}\}\}) \\ \text{Betrachte PANr} \rightarrow \text{Land} \rightarrow \text{Staat. Neue Relationen:} \end{array}$ 

1.  $R_1 = \{Land, Staat\}$ 

2.  $R_2 = \{PANr, PLZ, Ort, Land\}$ 

Wiederholen mit  $\mathbb{R}_2$ 

Vorteile: 3NF, Verbundtreue

 $\underline{\text{Nachteile}}:$  Keine Abhängigkeitstreue, keine Minimalität, reihenfolgeabhängig, NP-vollständig (Schlüsselsuche)

#### Syntheseverfahren

Prinzip: Synthese formt Original-FD-Menge F in Menge von Schlüsselabhängigkeiten G so um, dass  $F\equiv G$ 

Abhängigkeitstreue integriert

 $3{\rm NF}$ und Minimalität werden reihenfolgeunabhängig erreicht polynomielle Zeitkomplexität

Übersicht:

1. Redundanzen eliminieren:

Entfernen unnötiger FDs und Attribute (f überflüssig wenn  $F \equiv F - \{f\}$ , überflüssige Attribute später)

FDs zu Äquivalenzklassen zusammenfassen:
 FDs in selber Klasse, wenn sie äquivalente linke Seiten haben → ein Relationenschema pro Äquivalenzklasse

Beispiel:  $F = \{A \rightarrow B, AB \rightarrow C, A \rightarrow C, B \rightarrow A, C \rightarrow E\}$ 

1. Redundante FDs:  $A \to C$  Stand:  $F' = \{A \to B, AB \to C, B \to A, C \to E\}$ 

2. Überflüssige Attribute: B in  $AB \to C$ Stand:  $F'' = \{A \to B, A \to C, B \to A, C \to E\}$ 

Äquivalenzklasse

3. Ergebnis Relationenschema:  $(ABC, \{\{A\}, \{B\}\}), (CE, \{\{C\}\})$ 

#### Mehrwertige Abhängigkeiten

Mehrwertige Abhängigkeit (multi value dependency, MVD):

Jeder Wert des abhängigen Attributes kommt in Kombination mit allen Werten der anderen Attribute vor

Redundanzbehaftet

Beispiel:

Kurs		Dozent
AHA	Silberschatz	John D
AHA	Silberschatz Nederpelt	John D
AHA	Silberschatz	William M
AHA	Nederpelt	$William\ M$

Neues Buch: für jeden Dozenten anlegen → MVD

## Vierte Normalform

Beispiel: Relation mit Attributen  ${\it Name},\,{\it Neffe},\,{\it Hobby}$ 

Es gelte MVD:  $Name \rightarrow$  Neffe

Wenn

(Heinrich, Martin, Autos) und (Heinrich, Thomas, Basteln)  $\in r,$ dann auch

(Heinrich, Martin, Basteln) und (Heinrich, Thomas, Autos)

Formal: r genügt MVD  $X \twoheadrightarrow Y \Leftrightarrow$ 

 $\forall t_1, t_2 \in r : [(t_1 \neq t_2 \land t_1(X) = t_2(X))$   $\Rightarrow \exists t_3 \in r : t_3(X) = t_1(X) \land t_3(Y) = t_1(Y) \land t_3(Z) = t_2(Z)]$ 

4NF: solche MVDs aufspalten

Trivial, wenn keine weiteren Attribute im zugehörigen Schema

### Prüfungsfragen

- Erläutern Sie die folgenden Begriffe: Redundanz, Funktionale Abhängigkeit, Normalform, Verbundtreue, Abhängigkeitstreue, Minimalität.
- 2. Erläutern Sie die Aussage: "Funktionale Abhängigkeiten beinhalten semantische Informationen."
- 3. Welche Anomalien kennen Sie? Erläutern Sie für jede dieser Anomalien, warum Sie störend ist.
- 4. Warum braucht man für Verbundtreue Kriterien, für Abhängigkeitstreue jedoch scheinbar nicht?
- Welche Normalformen kennen Sie? Sagen Sie umgangssprachlich, wie sie definiert sind.

#### VIII. RELATIONALE DATENBANKSPRACHEN

## Aggregatfunktionen

Prinzip: Berechnung eines Werts aus Werten eines Attributs Join (natural): Kartesisches Produkt zweier Relationen Weitere in Standard SQL: count(), sum(), min(), max(), avg()

venere in standard SQL. count(), sur

#### SQL-Kern

 $\underline{\operatorname{select}}$ 

Projektionsliste,

arithmetische Operationen und Aggregatfunktionen select distinct: keine Dopplungen

 $\underline{\text{from}}$ 

zu verwendende Relationen, ggf. Umbenennungen

 $\underline{\text{where}}$ 

Selektions- und Verbundbedingungen geschachtelte Anfragen (wieder SFW-Block)

group by

Gruppierung für Aggregatfunktionen

having

Selektionsbedingungen an Gruppen

#### Self-Join

Kartesisches Produkt einer Tabelle mit selbst Beispiel:

Vierspaltiges Ergebnis:

eins.Name, eins.Vorname, zwei.Name, zwei.Vorname

#### Kartesisches Produkt

Verbunde als explizite Operatoren:

select \* from Kuenstler cross join Titel

### Natürlicher Verbund

Oft besser als herkömmliche Formulierung, weil

- 1. übersichtlicher
- 2. weniger fehleranfällig (man vergisst leicht Attribut, wenn man alle aufzählen muss)

 $\textbf{select} \ * \ \textbf{from} \ \texttt{Kuenstler} \ \textbf{natural} \ \textbf{join} \ \texttt{Titel}$ 

# Theta-Join

Verbund über Verbundsbedingungen

select \* from Kuenstler
 join Titel on Kuenstler.KID = Titel.KID

Beispiel: (AutoModell, AutoPreis), (BootModell, BootPreis) Kunde will Boot und Auto, aber Boot soll billiger sein als Auto  $\leadsto$  Auto $\bowtie_{AutoPreis>BootPreis}$  Boot

### Outer, Left, Right Join



#### where

Trivial: where Buecher.Titel = "Titel" Verbundbedingung (alternativ):

select Buecher.Titel, Buecher\_Stichwort.Stichwort
 from Buecher, Buecher\_Stichwort
 where Buecher.ISBN = Buecher\_Stichwort.ISBN

like: Ungewissheitsselektion (RegEx)
where attribut like spezialkonstante
in: where ISBN in (select ISBN from Empfiehlt)

Mengen - Vereinigung

select A, B, C from R1 union
 select A, C, D from R2

union: Duplikate werden eliminiert
union all: Duplikate werden behalten

#### Mengen - Differenz

Alle Mitarbeiter, die keine Studierenden sind:

select PANr from Mitarbeiter
 EXCEPT select PANr from Studenten

#### Mengen - Durchschnitt

Alle Mitarbeiter, die auch Studenten sind:

#### Umbenennung

select ISBN, Preis \* 1.44 as DollarPreis
 from BuchVersionen

## Grouping

Marke	Datum	Bundesland	Anzahl
BMW	07.01. 1994	Hessen	28
BMW	08.01. 1994	Bayern	37
BMW	07.01. 1994	Saarland	41
Opel	07.01. 1994	Hessen	48
Opel	08.01. 1994	Bayern	62
Opel	08.01. 1994	Saarland	5
Opel	09.01. 1994	Saarland	95
Audi	07.01. 1994	Hessen	55
Audi	08.01. 1994	Bayern	52
Audi	09.01. 1994	Bayern	27
Audi	10.01. 1994	Bayern	62

select Marke, sum(Anzahl)
 from Zulassungen
 group by Marke

select Marke, max(Anzahl)
 from Zulassungen
 group by Marke

# having-Bedingung:

select PANr, sum(Entlohnung)
 from anstellungen
 group by PANr
 having sum(entlohnung) > 10000

# Quantoren

any/some:

select PANr, ImmaDatum
 from Studenten
 where MatNr = any (select MatNr from Prueft)

all:

#### Sortieren

```
\label{eq:corder_by-Klausel:} \text{order by-} Klausel:
```

```
select MatNr, Note from Prueft
  where V_Bez = 'DBS'
    order by Note asc
```

alternativ: desc

#### Nullwerte

Vergleiche mit Nullwert: unknown statt true oder false  $\rightsquigarrow A = A$  keine Tautologie!

#### Update

```
update relation set attribut1 = wert, ...
[where bedingung]
```

#### Delete

```
delete from relation [where bedingung]
```

#### Insert

#### Prüfungsfrager

- 1. Formulieren diverser (komplexer) SQL-Anfragen
- 2. Vorgegebene geschachtelte Anfrage als nichtgeschachtelte schreiben
- 3. Welche Join-Varianten kennen Sie?
- 4. Geben Sie ein Beispiel an, in dem ein Self-Join sinnvoll ist.
- 5. Was ist der Zusammenhang zwischen Vereinigung und Outer Join?
- 6. Was ist eine Umbenennung im SQL-Kontext? Wann wird sie gebraucht?
- 7. Geben Sie ein sinnvolles Beispiel für eine Anfrage an, die eine having-Klausel hat.
- 8. Geben Sie ein Bespiel für eine Anfrage mit einer having-Klausel an, bei der man
  - (a) die Klausel durch eine where-Klausel ersetzen kann,
  - (b) das nicht kann.
- 9. Erläutern Sie, warum im SQL-Kontext "A==A" keine Tautologie ist.

# IX. NEBENLÄUFIGKEIT, TRANSAKTIONEN

#### Transaktion

Partiell geordnete Folge von Lese- und Schreibzugriffen auf Datenobjekte (mit Commit oder Abort am Ende)

## ACID Eigenschaften:

Atomicity: Entweder alles oder gar nichts ausführen Consistency: Integritätsbedingungen bleiben erhalten Isolation: Nutzer hat Eindruck, er wäre alleine Durability: Änderungen sollen dauerhaft sein

#### Synchronisation

Viele Nutzer sollen Daten gleichzeitig lesen und schreiben können

→ Konsistenz sicherstellen → Synchronisationskomponente
Serielle Ausführung:

- + Konsistenz immer gewährleistet
- extreme Wartezeiten, schlechte Ressourcenausnutzung

#### Unkontrollierte nicht-serielle Ausführung: Probleme

#### Lost Update

Programm  $T_1$  transferiert 300 EUR von Konto A nach B, Programm  $T_2$  schreibt Konto A 3% Zinsen gut  $\leadsto$  Zinsen aus  $S_5$  von  $T_2$  verloren, weil  $T_1$  in  $S_6$  überschreibt

Schritt	T1	T2
1	Read(A, a1)	
2	a1 := a1-300	
3		Read(A, a2)
4		a2 := a2 *1.03
5		Write(A, a2)
6	Write(A, a1)	
7	Read(B, b1)	
8	b1 := b1 + 300	
9	Write(B, b1)	

#### Dirty Read

Commit, Abort

 $T_2$ schreibt Zinsen gut basierend auf einem Wert, der nicht zu einem konsistenten Zustand gehört, denn später erfolgt Abort von  $T_1$ 

Schritt	T1	T2
1	Read(A, a1)	
2	a1 := a1-300	
3	Write(A, a1)	
4		Read(A, a2)
5		a2 := a2 *1.03
6		Write(A, a2)
7		commit
8	Read(B, b1)	
9		
10	abort	

# Non-Repeatable Reads

Programm liest Datenobjekt mehr als einmal und sieht dabei Änderung durch anderes Programm

Schritt	T1	T2
1	Read(A, a1)	
2	a1 := a1-300	
3	Write(A, a1)	
4		Read(A, a2)
5		a2 := a2 *1.03
6		Write(A, a2)
7	Read(A, a3)	
8		

### Phantom

Berechnung von Änderung auf veralteten Werten

### Konflikt

Zwei Operationen p,q konfligieren

 $\Leftrightarrow p, \hat{q}$ greifen auf selbes Datenobjekt zu und poder qist Schreiboperation

In einer Transaktion müssen konfligierende Operationen **geordnet sein** (andere nicht zwingend)

#### Histories

Vollständige Historie: Menge von Transaktionen und Ausführungsordnung (nebenläufige Verzahnung, Ordnung konfligierender Operationen zwischen Transaktionen)

Historie: Präfix einer vollständigen Historie

Committed Projection (C(H)): H nach Entfernen aller nichtcommitteten Operationen

Eine Eigenschaft von Histories ist prefix commit closed  $\Leftrightarrow$  (H erfüllt Eigenschaft  $\Rightarrow$  C(H') erfüllt Eigenschaft)

## Konfliktäquivalenz (CSR)

 $H,H^{\prime}$  (Konflikt-) Äquivalent, wenn

- 1. gleiche Transaktionen, gleiche Operationen
- 2. gleiche Ordnung konfligierender Operationen (gleiche Konfliktrelation)

#### Serialisierbarkeit

H serialisierbar  $\Leftrightarrow C(H) \equiv H_S$  (serielle History)

Serialisierbarkeitsgraph (Abhängigkeitsgraph):

Knoten = Transaktionen

(gerichtete) Kante von  $T_1$  nach  $T_2$  wenn  $op_1$  und  $op_2$  konfligieren und  $op_1 < op_2$ 

Theorem: Schedule ist serialisierbar, wenn entsprechender Abhängigkeitsgraph zykelfrei ist

Konflikt-Serialisierbarkeit ist prefix commit-closed

#### Ansatz nicht praktikabel:

- 1. Serialisierbarkeit nur im Nachhinein überprüfbar
- 2. Administrativer Overhead zu hoch: Abhängigkeiten zu bereits terminierten Transaktionen berücksichtigen

#### Rücksetzbarkeitsklassen

Rücksetzbar (RC): Commit für  $T_j$  erst erlaubt, wenn alle  $T_i$  von denen  $T_i$  liest, committed sind (Abort darf Semantik von bereits committeten Transaktionen nicht verändern).

Avoid cascading aborts (ACA): Nur Objekte von bereits committeten Transaktionen lesen.

Striktheit (ST): Objekte von noch nicht committeten Transaktionen dürfen weder gelesen noch überschrieben werden (ermöglicht einfache Implementierung des Rücksetzens)

# Locking

Lock für jedes Datenobjekt und jede Operationsart Notation:  $rl_i[x]$ ,  $wl_i[x]$ 

Aber: Sperrdisziplin alleine reicht für Korrektheit nicht aus!

# Zwei-Phasen-Sperrprotokoll (2PL):

- 1. Locks werden hinzugenommen
- 2. Locks werden freigegeben

→ Serialisierbarkeit sichergestellt Deadlocks sowie kaskadierende Abbrüche weiterhin möglich

# Strenges Zwei-Phasen-Sperrprotokoll (S2PL):

Atomare Freigabephase am Ende der Transaktion → Zusätzlich ACA: Vermeidung kaskadierender Abbrüche

## Konservatives Zwei-Phasen-Sperrprotokoll (C2PL):

Atomare Anforderungsphase zu Beginn der Transaktion → Zusätzlich: Vermeidet Deadlocks

### CS2PL:

Kombination aus streng und konservativ: Atomare Anforderungs- und atomare Freigabephase → Serialisierbarkeit, ACA, Deadlockfreiheit

Aber: Jede Einschränkung schränkt auch die Zahl der möglichen Histories ein und verringert damit den möglichen Grad der Parallelität!

#### Prüfungsfragen

- 1. Was ist Isolation? Was ist der Zusammenhang zwischen Isolation und Serialisierbarkeit?
- 2. Welche Probleme können bei unkontrollierter nebenläufiger Ausführung von Transaktionen auftreten?
- 3. Beispiele für Lost Updates, Non-Repeatable Reads usw. angeben, die bestimmte Bedingungen erfüllen
- 4. Warum ist es wichtig, dass unser Korrektheitskriterium für Histories prefix commit closed ist? Erklären Sie. warum Konflikt-Serialisierbarkeit prefix commit closed
- 5. Ist eine gegebene History serialisierbar/recoverable/cascadeless
- 6. Haben zwei Konflikt-äquivalente Histories stets die gleichen Reads-from-Beziehungen?
- 7. Warum verwendet man in der Regel nicht den Serialisierbarkeitsgraphen, um Serialisierbarkeit sicherzustellen?
- 8. Bei Deadlocks wird in der Regel eine Transaktion zurückgesetzt. Kann es vorkommen, dass die gleiche Transaktion mehrmals/beliebig oft zurückgesetzt wird? Wenn ja, was kann man jeweils dagegen tun?
- 9. Geben Sie ein Beispiel für eine serialisierbare Ausführung, bestehend aus drei Transaktionen, mit folgender Eigenschaft an: Die zeitliche Reihenfolge der Commits ist  $c_1$  vor  $c_2$  vor  $c_3$ , die der äquivalenten seriellen Ausführung jedoch  $c_3$  vor  $c_2$  vor  $c_1$ .
- 10. Um einen Deadlock aufzulösen muss eine der beteiligten Transaktionen zurückgesetzt werden. Welche Kriterien sind Ihres Erachtens nach sinnvoll, um diese Auswahl zu treffen?

### X. CLOUDSYSTEME – KONSISTENZ

# Verteilung

Vorteile (scheinbar):

- 1. Leselastverteilung
- Beschleunigung (durch höhere Lokalität)
   Höhere Ausfallsicherheit

### Nachteile:

- Transaktionen müssen auf Knoten gleich angeordnet sein
- Widerspruchsfreie Anordnungsentscheidungen nötig für Konfliktfreiheit  $\leadsto$  schlechte Skalierbarkeit
- 3. Für Konsistenz müssen alle Knoten verfügbar sein  $\leadsto$  geringere Ausfallsicherheit
- → Netzwerkpartitionierung

CAP-Theorem: Wenn Netzwerkpartitionierung möglich, dann sind hohe Verfügbarkeit und Datenbestandskonsistenz unvereinbar

## **Eventual Consistency**

"Wenn ab Zeitpunkt keine Änderungen mehr, dann werden irgendwann alle Lesezugriffe gleichen Wert zurückliefern

Alternativ: "...dann werden irgendwann alle Lesezugriffe zuletzt geschriebenen Wert zurückliefern"

Beispiel (social network): Netzwerkpartition

Starke Konsistenz: Vorübergehend keine Postings möglich Eventual Consistency: User kann Posting schreiben, Follower sehen es sobald möglich

- 1. Geben Sie die Probleme mit dem klassischen, starken Konsistenzbegriff im verteilten Fall wieder.
- 2. Bekommt man mit eventual consitency irgendeine Form von Sicherheit? Begründen Sie Ihre Antwort.
- 3. Warum kann man im Bank-Kontext in manchen Situationen doch auf starke, klassische Konsistenz verzichten?
- 4. Geben Sie ein weiteres Beispiel für eine Folge von Operationen, deren Anordnung egal ist.

# XI. CLOUDSYSTEME - FUNKTIONALITÄT

#### Was ändert sich in der Cloud?

Physischer Entwurf muss automatisch erfolgen

Obligatorische Datenverteilung

Anfrageauswertung in Gegenwart anderer Anfragen

→ entsprechende Planung

Unterschiedliche QoS-Vereinbarungen mit unterschiedlichen Dienstnehmern

Plötzliche extreme Zunahme von Zugriffen eines Dienstnehmers i.A. nicht vorhersehbar

 $\leadsto$  Infrastruktur sollte damit umgehen können

Secure Storage: Verschlüsselung der Daten, trotzdem soll Dienstanbieter möglichst großen Teil der Anfrageauswertung übernehmen

## Relationale Algebra

 $\frac{\text{Projektion: Optimierung: bei vielen Projektionen hintereinander}}{\text{reicht die zuletzt ausgeführte auch allein:}}$ 

 $\pi[\text{KName}](\pi[\text{KName}, \text{Land}](\text{Kuenstler})) \leadsto \pi[\text{KName}](\text{Kuenstler})$ 

 $\underline{{\bf Selektion}}.$  Optimierung: Selektionen lassen sich beliebig vertauschen, manchmal auch Projektion und Selektion

Verbund: Kommutativ, Assoziativ

Nested-Loop Join: Teuer, da pro Eintrag links über alle rechten Einträge iteriert wird

Merge Join: Beide Relationen sortieren, dann Eintrag für Eintrag

## Blockierende/Nichtblockierende Operatoren

Operator blockiert  $\Leftrightarrow$  Ergebnis des Operators muss vor Ausführung des nachfolgenden vollständig berechnet sein (z.B. Sort-Operator)

# Histogramme

Zeigt Auftrittshäufigkeit eines Intervalls

Equi-Width-Histogramm: Breite aller Buckets gleich

 $\underline{\underline{\text{Equi-Depth-Histogramm}}} \colon \text{Auftrittsh\"{a}ufigkeit aller Buckets gleich}$ 

Nützlich bei ein-Attribut-Anfragen, sonst nicht so:

Mehrdimensionale Histogramme schwer konstruierbar und wartbar, Anzahl Attributkombinationen exponentiell wachsend zur Anzahl der Attribute

# Synchroner und asynchroner Zugriff

Synchron: innerhalb einer Transaktion Asynchron: mehrere Transaktionen

## Service-Level Agreements

Vereinbarung zwischen Client und Server bzgl. Dienstausführung "Antwort innserhalb von 300ms für 99,9% der Aufrufe bei 500 Zugriffen pro Sekunde"

## Zustände

 $\underline{\text{Zustandslos}}$ : z.B. Umrechnungsdienst

Zustandsbehaftet: z.B. Ausführung Geschäftsprozess

### Quorum

Szenario: Replikation mit n Knoten

 $\leadsto$  Wie Konsistenz sicherstellen? Was, wenn nicht alle Knoten verfügbar?

## Quorum Consensus:

Lesen: Lese Mindestanzahl von Versionen (R), nehme aktuelle Schreiben: Aktualisiere Mindestanzahl von Kopien (W)  $\leadsto$  Für Lesen/Schreiben muss eine festgelegte Anzahl an Knoten zustimmen. Forderungen (N=Anzahl Knoten):

$$1. \ Q_R + Q_W > N$$

 $2. \ 2Q_W > N$ 

#### P2P

 $peer\ to\ peer\mbox{-}\mbox{Systeme};$ 

Jeder Knoten für Ausschnitt des Schlüsselraums verantwortlich Verwaltung von (Schlüssel, Wert)-Paaren

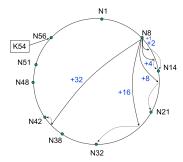
(put, get)-Interface

Zu Größe des Schlüsselraums logarithmischer Suchaufwand

Beispiel: Chord

Zentrale Datenstruktur: identifier circle, chord ring

Suche: Jeder Knoten hat finger table, i-ter Eintrag von Knoten n:  $successor(n+2^{i-1})$  (m Anzahl Bits)



Replikation über  $chained\ replication$ : Schlüssel nicht nur bei einem Knoten, sondern auch bei k Nachfolgern einfügen

 $\frac{\text{Heterogenität: Knoten können unterschiedlich leistungsstark sein}}{(\text{ggf. unterschiedliche Zuständigkeitsbereiche, unterschiedliche Last})}$ 

#### Dynamo

Key-Value-Store

get-/put-Interface

Objekte BLOBs  $\leadsto$ kein DB-Schema  $\leadsto$  Interpretieren nötig

Keine Isolation  $\leadsto$  keine totale Konsistenz

Schreibzugriff jeweils nur für ein Objekt

Problem	Technik	Vorteil
Partitionierung	Consistent Hashing	Skalierbarkeit, inkrementell
Hohe Verfügbarkeit für das Schreiben	Vector Clocks mit Abgleich beim Lesen	
Umgang mit vorübergehenden Ausfällen	Sloppy Quorum mit hinted handoff	Hohe Verfügbarkeit und Dauerhaftigkeit
Recovery	Anti-Entropy	Synchronisation läuft im Hintergrund ab.
Erkennen von Ausfällen	Gossip-basierte Protokolle	Deckt Anforderung ,Symmetrie' ab.

### Dynamo - Vector Clocks

Ziel: eventual consistency

Liste von (Knoten, Zähler)-Paaren (eine Liste pro Version)  $\leadsto$  Erfassung der Zusammenhönge zwischen Versionen

Quorum-basierte Techniken  $\leadsto$  Inkonsistenzen vermeiden

vector clock-basierte Techniken  $\leadsto$  Inkonsistenzen erkennen und auflösen

Unterschiedliche Knoten können Schreiboperationen absetzen  $\leadsto$  Differenzierung

Version 1 ist Vorgänger von Version 2, wenn jeder Zähler in List von V1 einen kleineren Wert hat als in der von V2

Update (put) muss festlegen, welche Version aktualisiert werden

Get gibt i.A. mehrere Versionen zurück

#### Scale Independence

Anfrage ist scale-independent

 $\leadsto$  Laufzeitverhalten unabhängig von DB-Größe

Anfragenklassifikation nach Aufwand:

1. Klasse I (konstant):

z.B. ID-basierter Zugriff,  ${\tt LIMIT\text{-}}{\tt beschränkte}$  Anfragen 2

2. Klasse II (beschränkt):

Explizite Begrenzung liegt vor

Als Kardinalität im erweiterten DB-Schema darstellbar

3. Klasse III ((sub-)linear):

z.B. Ausgabe aller Kunden/Produkte

4. Klasse IV (superlinear):

z.B. Clustering-Algo, der Self-Join der zugrundeliegenden Relation ausführt

→ PIQL (performance insightful query language) - Scale Independent durch Erweiterungen und Beschränkungen der Anfragesprache

#### Ergebnisgröße

Wie bestimmte Größe des Anfrageergebnisses garantieren?

→ LIMIT, Pagination, Berücksichtigung von Fremdschlüsselbeziehungen, Erweiterung DB-Schema um Kardinalitäten

#### Physische Optimierung

Zwei Arten von physischen Operatoren:

- ${\it 1. \ remote \ operator:} \ {\it Zugriffe \ auf \ key-value \ store \ und \ elementare \ Verarbeitungsschritte}$
- 2. Client-seitige Operatoren für Query-Logik

Remote Operator: Muss explizite Beschränkung der Größe des Zwischenergebnisses enthalten (i.A. stop-Operator in Operator-Darstellung)

Remote-Operatoren:

- IndexScan: Prädikat muss zusammenhängendem Ausschnitt des indexierten Wertebereichs entsprechen, "Sort" muss Sortierreihenfolge des Index sein
- 2. **IndexForeignKeyJoin**: Beschränkung durch Fremdschlüsseleigenschaft → kein logischer Stop-Operator, linker Teilausdruck enthält Fremdschlüssel
- 3. **SortedIndexJoin**: Bei Sortierung des Inputs nach Join Key lässt sich aus limit hint-Begrenzuung der Anzahl an Datenobjekten pro Schlüssel ableiten

## SLO Compliance-Vorhersage

SLO = serivce-level objectives

Größenbeschränkung Zwischenergebnisse noch keine Garantie für insgesamt beschränkten Aufwand

Wenn anliegende Last sehr groß kann IndexScan-Ausführung beliebig lange dauern

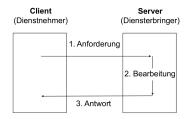
Lookup über Zufallsverteilung (Parameter Tupelgröße, Anzahl erwarteter Tupel)

### Prüfungsfrager

- 1. Was für Möglichkeiten kennen Sie, den Join zu implementieren? Weche Komplexität haben sie?
- 2. Welche Möglichkeiten kennen Sie, den Aufwand, den eine Anfrage verursacht, zu reduzieren/begrenzen?

### XII. ANWENDUNGSENTWICKLUNG

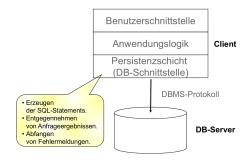
# Client-Server-Architektur



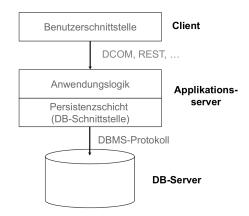
#### Erfordert

- 1. Kenntnis über angebotene Dienste
- 2. Protokoll zur Regelung der Interaktion

#### Zwei Schichten-Architektur



#### Drei Schichten-Architektur



# Anwendungslogik

 $\frac{\text{Anwendungslogik:}}{\text{sen beinhalten}} \cdot \text{Algorithmen, die anwendungsspezifisches Wissen beinhalten}$ 

Personal-DB entählt Mitarbeiter-Daten

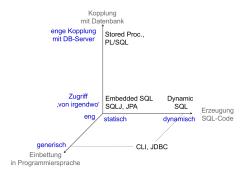
- → Anwendung: schlägt Teamleiter für konkrete Projekte vor
- → Bedeutsamkeit der Fähigkeiten usw. Anwendungsteil

# Cursor-Konzept

 $Cursor \equiv Iterator$ 

Programmiersprachen: einzelne Datenobjekte als zugrundeliegende Struktur

## Programmiersprachenanbindung



## **Prepared Statements**

Reduzieren Ausführungszeit, da bereits vorab kompiliert

```
{\tt PreparedStatement\ updateSales\ =\ }
    con.prepareStatement('UPDATE COFFEES
   SET SALES = ? WHERE COF_NAME LIKE ?');
upcdateSales.setInt(1,75);
```

#### Gespeicherte Prozeduren

In DB-Server verwaltete und ausgeführte Software-Module in Form von Prozeduren/Funktionen

Aufruf aus Anwendungen/Anfragen heraus

→ Weniger Kontextwechsel in Anwendung

#### Variablen und Typen

```
DECLARE preis NUMBER;
Stellt sicher, dass Attributtyp in DB identisch zu Typ in Pro-
```

## ${\bf Kontroll fluss}$

```
DECLARE
  a NUMBER;
  b NUMBER;
BEGIN
  SELECT e,f INTO a,b
FROM T1 WHERE e>1;
IF b=1 THEN
     INSERT INTO T1 VALUES(b,a);
  ELSE
     INSERT INTO T1 VALUES(b+10,a+10);
  END IF;
FND ·
run;
```

## Performance Anti-Patterns

Excessive Dynamic Allocation:

Häufige unnötige Objekterstellung/-zerstörung derselben Klasse

The Stifle:

Unpassende DB-Schnittstellennutzung

<u>Circuitous Treasure Hunt</u>:

Abfrage von Relation A, damit Relation B abfragen,...

Sisyphus DB Retrieval:

Riesige Datenmenge abfragen, obwohl nur wenige Einträge nötig

 $\underline{\operatorname{Spaghetti}}\ \operatorname{Query:}$ 

Mehrere Informationsbedürfnisse in einer Anfrage

Insufficient Caching: Zu wenig Caching

 $\frac{ \text{Wrong Caching Strategy:}}{\text{Falsche Objekte werden in Cache abgelegt}}$ 

- 1. Erläutern Sie die Dimensionen des Raums der Möglichkeiten des Zugriffs auf Datenbanken aus Anwendungen
- 2. Erläutern Sie die Begriffe
  - (a) Anwendungslogik,
  - (b) Cursor,
  - (c) Call-Level Interface,
  - (d) Host-Variablen.
- 3. Kann man mit Embedded SQL sicherstellen, dass keine Schema-spezifischen Fehler auftreten? Wenn ja, wie geht es?
- 4. Was sind die Vorteile von Stored Procedures? Erläutern Sie das Konzept.